



Poszukiwania miejsca pracy w obszarze

Big Data i Data Science

Indukowane reguły decyzyjne - raport zaliczeniowy

Olga Lewandowska, nr albumu: 113944

Krzysztof Owczarek, nr albumu: 114505

Julia Cymbalista, nr albumu: 114021

Aleksandra Nowak, nr albumu: 122137

Mikołaj Rostkowski, nr albumu: 114191

Warszawa, Styczeń 2024

SPIS TREŚCI

1. Podsumowanie	3
1.1 Problem decyzyjny	3
1.2 Wykorzystane dane	3
1.3 Uzyskany wynik	3
2. Dane	4
2.1 Źródło danych	4
2.2 Wielkość	4
2.3 Zmienna objaśniana	4
2.3.1 Typ	4
2.3.2 Oznaczenia wartości	4
2.3.3 Udział kategorii	5
2.4 Analiza i przekształcenia danych	6
2.5 Zmienne objaśniające	11
2.5.1 Typy	11
2.5.2 Rozkłady zmiennych	11
2.5.3 Korelacja i współzależność. Siła predykcji	13
3. Model	14
3.1 Narzędzie	14
3.2 Algorytm i ustawienia	14
3.3 Zmienne potencjalne i w modelu	15
3.4 Wynik i kolejne etapy budowania modelu	16
4. Ocena jakości	25
4.1 Zbiór wykorzystany do oceny jakości	25
4.2 Wskaźniki oceny jakości modeli	25
4.2.1 Porównanie tree_1.2 oraz tree_2.3_final	25
4.2.2 Porównanie tree_2.3_final oraz lasu rf_2.3	28
4.3 Wybór modelu	30
5. Wyniki i interpretacja	30
5.1 Wyniki “techniczne”	30
5.2 Interpretacja	31
6. Bibliografia	31

1. Podsumowanie

1.1 Problem decyzyjny

Problemem decyzyjnym przeprowadzonej analizy jest próba odpowiedzenia na pytanie *Co ma największy wpływ na podjęcie decyzji o poszukiwaniu nowego miejsca pracy w obszarze Big Data po zakończonym szkoleniu?* Próba odpowiedzi jest oparta na zmiennej objaśnianej. W zbiorze danych jest to zmienna *target*, która jest zmienną binarną.

Firma z obszaru Big Data i Data Science chce zatrudnić specjalistów, którzy z powodzeniem ukończyli kursy organizowane przez wspomnianą firmę. Szkolenia realizowane przez firmę cieszą się dużym powodzeniem, jednak nie każdy planuje pozostanie w niej po ukończonych kursach. Firma chce dowiedzieć się co wpływa na podjęcie takiej decyzji, a także ile realnie kursantów zacznie poszukiwania nowej pracy. Pomoże to zmniejszyć koszty i ograniczyć czas, a także poprawić jakość szkolenia, planowanie kursów i kategoryzację kandydatów.

1.2 Wykorzystane dane

Do przeprowadzenia analizy wykorzystano zbiór danych zawierający 19158 obserwacji. Początkowo zbiór zawierał 14 zmiennych, jednak po dokonaniu zmian pozostało 8 zmiennych, w tym zmienna objaśniana *target*. Na podstawie tej zmiennej zbiór został podzielony na 4777 obserwacji należących do klasy pozytywnej (chęć zmiany firmy) oraz 14381 obserwacji należących do klasy negatywnej (brak chęci zmiany firmy).

1.3 Uzyskany wynik

Na podstawie uzyskanych wyników stwierdziliśmy, że najlepszym modelem będzie las *rf_2.3*. W porównaniu do pozostałych posiada najlepsze wartości odpowiednich wskaźników. Biorąc jednak pod uwagę wartości R-kwadrat, skorygowanego R-kwadrat oraz korelacji zmiennych objaśniających do zmiennej objaśnianej stwierdzamy, że model ma umiarkowanie słabą skuteczność w wyborze czynników, które mają wpływ na wybory kursantów. Firma powinna dostarczyć więcej danych, zawierających dodatkowe zmienne w celu lepszej analizy problemu.

2. Dane

2.1 Źródło danych

Do opracowania wykorzystano dane, które zostały pozyskane z bazy zawierającej zebrane i uszeregowane wcześniej zmienne objaśniające i zmienną objaśnianą. Znajdują się one na stronie [kaggle.com](https://www.kaggle.com/datasets/arashnic/hr-analytics-job-change-of-data-scientists) i zostały na niej udostępnione w ramach domeny publicznej CC0.

Link: <https://www.kaggle.com/datasets/arashnic/hr-analytics-job-change-of-data-scientists>¹

Dzięki uszeregowanym danym uzyskano pełen dostęp do różnych zmiennych z zakresu HR, co stanowiło istotne źródło w konstrukcji raportu.

2.2 Wielkość

Przed zmianami zbiór badawczy danych zawierał 19158 obserwacji oraz 14 zmiennych. W procesie zmian dodaliśmy 1 zmienną oraz usunęliśmy 7 zmiennych. Finalnie w zbiorze danych pozostało nadal 19158 obserwacji, jednak ograniczony został do 8 zmiennych.

Dodatkowo w celu zniwelowania różnic pomiędzy klasą pozytywną i negatywną w ilości obserwacji, wykonaliśmy oversampling, który spowodował, że do finalnej analizy mieliśmy 8 zmiennych oraz 42993 obserwacji. Przy tworzeniu lasu zmniejszyliśmy obserwacje o te zawierające “NA” i otrzymaliśmy ich 41106.

2.3 Zmienna objaśniana

2.3.1 Typ

Dokonując analizy danych skoncentrowaliśmy się na zmiennej objaśnianej *target*. Jest to zmienna binarna, która opisuje, czy dany kursant chce po zakończeniu szkolenia w firmie znaleźć nową pracę lub pozostać w tej, w której odbywały się kursy.

2.3.2 Oznaczenia wartości

Jako, że zmienna *target* jest zmienną binarną, w bazie danych mamy do czynienia z oznaczeniami:

¹ stan na dzień: 10.01.2024 r.


- “1”: klasa obejmuje osoby, które po ukończonym kursie zdecydowały się szukać nowej pracy. Takich osób chce uniknąć firma, ponieważ generują dodatkowe koszty i marnują czas, który firma mogłaby przeznaczyć np. na dalszy rozwój pozostających pracowników.
- “0”: klasa obejmuje osoby, które po ukończonym kursie nie zdecydowały się szukać nowej pracy. Na takich osobach najbardziej zależy firmie, w celu ograniczenia czasu i kosztów.

2.3.3 Udział kategorii

W użytym zbiorze danych, udział poszczególnych kategorii przedstawia się następująco:

- Kategoria pozytywna (1): obejmuje 24,9% całego zbioru danych, co odpowiada 4777 obserwacjom. Oznacza to, że 24,9% osób, które uczęszczały na kurs organizowany przez firmę zdecydowało, że poszuka nowej pracy.
- Kategoria negatywna (0) obejmuje 75,1% całego zbioru danych, co odpowiada 14381 obserwacjom. Oznacza to, że 75,1% osób, które uczęszczały na kurs organizowany przez firmę zdecydowało, że pozostanie w firmie.

Wyk. 1.1



Źródło: opracowanie własne w programie RStudio

2.4 Analiza i przekształcenia danych

Przed przeprowadzeniem analizy dokonano odpowiednich przekształceń zmiennych. Początkowo została wprowadzona kosmetyczna poprawka literówki w nazwie zmiennej *relevant_experience*. Po przeanalizowaniu zmiennych zauważono, że może mieć sens dodanie zmiennej *Count*, obrazującej ilość ankiet, które spłynęły z danego miasta. Na jej podstawie można uszeregować miasta w zależności od jej liczebności. Sprawdziliśmy na podstawie drzewa ze zmienną *Count* oraz jego macierzy błędów, że przy pomocy tej zmiennej można budować sensowne węzły, zatem zdecydowaliśmy o pozostawieniu jej w zbiorze danych (rysunek 1.1; rysunek 1.2).

Rys. 1.1

Confusion Matrix and Statistics

	0	1
0	3330	823
1	262	405

Accuracy : 0.7749

95% CI : (0.7628, 0.7866)

No Information Rate : 0.7452

P-Value [Acc > NIR] : 9.137e-07

Kappa : 0.3023

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9271

Specificity : 0.3298

Pos Pred Value : 0.8018

Neg Pred Value : 0.6072

Prevalence : 0.7452


Detection Rate : 0.6909

Detection Prevalence : 0.8616

Balanced Accuracy : 0.6284

Źródło: opracowanie własne w programie RStudio

Rys. 1.2



Źródło: opracowanie własne w programie RStudio

Następnie puste elementy zbioru zostały wypełnione wartością “NA” oraz została wyczyszczona kolumna *experience* zawierająca dane “>20” i “<1”, co uniemożliwiłoby nam działanie na wartościach numerycznych.

Rys. 1.3

```


##wypełnienie pustych komórek wartością NA
aug_2[aug_2 == "" ] <- NA

##czyszczenie kolumny experience
aug_2$experience[aug_2$experience==">20"] <- "25"
aug_2$experience[aug_2$experience=="<1"] <- "0"
aug_2$experience <- as.numeric(aug_2$experience)
  
```

Źródło: opracowanie własne w programie RStudio

Zdecydowaliśmy się usunąć zmienne *company_type*, *company_size*, *gender* oraz *major_discipline*. Te zmienne zawierały dużo wartości “NA”, co powoduje, że są one nieprzydatne (z wyjątkiem zmiennej *experience*), (wykres 1.2).


Wyk. 1.2



Źródło: opracowanie własne w programie RStudio

Dodatkowo w zmiennej *gender* występuje bardzo duża przewaga mężczyzn, a prawie $\frac{1}{3}$ to braki danych, zatem zmienna ta nie odzwierciedla prawdziwego obrazu sytuacji (wykres 1.3). Co więcej, w celu identyfikacji zmiennych istotnych wykonaliśmy funkcję regresji logistycznej, z której wynika, że zmienne *gender* oraz *last_new_job* są nieistotne (rysunek 1.3). Postanowiliśmy również usunąć *enrollee_id* oraz *city*, ponieważ było to tylko oznaczenie ID kandydata oraz numery kolejnych miast, co nie jest istotne w analizie.

Wyk. 1.3



Źródło: opracowanie własne w programie RStudio


Rys. 1.4

(Intercept)	***
Count	***
genderMale	
genderOther	
relevant_experienceNo relevant experience	***
enrolled_universityno_enrollment	***
enrolled_universityPart time course	***
education_levelHigh School	***
education_levelMasters	**
education_levelPhd	
education_levelPrimary School	***
experience	***
last_new_job1	
last_new_job2	
last_new_job3	
last_new_job4	
last_new_jobnever	*
training_hours	*
city_development_index	***

Źródło: opracowanie własne w programie RStudio

Oprócz dużej ilości “NA” w zmiennej *major_discipline*, pozostałe wyniki w większości zawierały się w obserwacji “STEM”, więc taka zmienna również z tego powodu nie byłaby przydatna w dalszej analizie (wykres 1.4).

Wyk. 1.4



Źródło: opracowanie własne

2.5 Zmienne objaśniające


2.5.1 Typy



Zbiór danych początkowo zawierał 13 zmiennych objaśniających. Po przekształceniach pozostało ich 7. Poniżej zostały opisane wszystkie zmienne, które nie zostały usunięte ze zbioru:


- city_development_index: indeks rozwoju miasta w skali od 0 do 1 (wyrażony numerycznie);
- relevant_experience: odpowiedni poziom doświadczenia kandydata; zmienna binarna z opcjami “Has relevant experience” oraz “No relevant experience”;
- enrolled_university: tryb studiów kandydata, jeżeli uczęszcza;
- education_level: poziom edukacji kandydata;
- experience: lata doświadczenia zawodowego kandydata (wyrażony numerycznie);
- training_hours: ukończona liczba godzin kursu (wyrażony numerycznie);
- Count: zmienna utworzona oznaczająca ilość ankiet, które spłynęły z danego miasta (wyrażona numerycznie);

2.5.2 Rozkłady zmiennych

Wyk 1.5 - 1.8







Źródło: opracowanie własne w programie RStudio

Biorąc pod uwagę powyższe rozkłady zmiennych objaśniających można zauważyć podobny kształt dla rozkładów *training_hours* oraz *experience*. Daje to pewne informacje na temat lat doświadczenia i godzin szkolenia jakie posiadają osoby ubiegające się lub chcące zmienić firmę po jego zakończeniu.

Dodatkowo zmienna *city_development_index* również charakteryzuje się pewnym odstającym przedziałem. Jedynie rozkład zmiennej *count* różni się od pozostałych posiadając wysokie częstotliwości w skrajnych częściach wykresów.

Dla pozostałych zmiennych objaśniających nie udało się wygenerować rozkładów ze względu na ich nienumeryczną formę.

2.5.3 Korelacja i współzależność. Siła predykcji

Analizując otrzymane wskaźniki korelacji i współzależności pomiędzy zmiennymi objaśniającymi oraz zmienną objaśnianą zauważyliśmy, że występuje słaba lub bardzo słaba zależność pomiędzy zmiennymi. Z 4 zmiennych, dla których mogliśmy zbadać korelację, 3 wyszły ujemne, a 1 dodatnia (rysunek 1.4).

Rys. 1.4

kor_citydvpid	-0.341665085545229
kor_count	0.078957742356715
kor_experience	-0.169839021376644
kor_trainingh	-0.0215772497136133

Źródło: opracowanie własne w programie RStudio

Przekładając otrzymane wyniki na przyszłą analizę wnioskowaliśmy, że:

- ze względu na niską wartość korelacji, zmienne objaśniające mają niewielki wpływ na zmienną objaśnianą, co utrudnia wnioskowanie. Czynniki, które nie są ujęte mogą być silniejsze;
- słaba korelacja może również powodować niską predykcję oparta na tych zmiennych;
- może być konieczne zawarcie dodatkowych czynników lub metod w celu lepszej analizy badanego zjawiska.

Co więcej, wartość R-kwadrat dla wszystkich 8 zmiennych objaśniających, które uwzględniliśmy w modelu wyszła 0,1615, a skorygowany R-kwadrat 0.161. Są to niskie wyniki, które potwierdzają wcześniej otrzymane obserwacje słabej korelacji i niskiej sile predykcyjnej. Wartość ta świadczy również o tym, że zmienne objaśniające nie wyjaśniają znacznej części zmiennej objaśnianej.

3. Model

3.1 Narzędzie

Modele zostały wykonane przy pomocy programu RStudio, gdzie zostały również zwizualizowane drzewa i wykresy. Dla głębszej analizy stworzyliśmy ewaluacje modeli.

3.2 Algorytm i ustawienia

Na początku podzieliliśmy zbiór obserwacji na zbiór treningowy i testowy. Na początku testowaliśmy różne metody i tworzyliśmy drzewa:

- tree_1.1: minbucket = 47, maxdepth = 5, cp = 0,01; zmienne: *Count*, *relevant_experience*, *enrolled_university*, *education_level*, *experience*, *training_hours*;

- tree_1.2: minbucket = 47, maxdepth = 5, cp = 0,01; zmienne: *Count*, *relevant_experience*, *enrolled_university*, *education_level*, *experience*, *training_hours*; *city_development_index*;
- tree_1.3: minbucket = 47, maxdepth = 30, cp = 0,01; zmienne: *Count*, *relevant_experience*, *enrolled_university*, *education_level*, *experience*, *training_hours*; *city_development_index*;

Po przeanalizowaniu drzew doszliśmy do wniosku, że mamy zbyt mało obserwacji z klasy “1” w porównaniu do klasy “0”, dlatego zastosowaliśmy metodę *smote*, aby zoversamplować obserwacje.

Po wykonaniu tej operacji utworzyliśmy następujące drzewa:

- tree_2.1: minbucket = 144, maxdepth = 5, cp = 0,01; zmienne: *Count*, *relevant_experience*, *enrolled_university*, *education_level*, *experience*, *training_hours*; *city_development_index*;
- tree_2.2: minbucket = 1500, maxdepth = 5, cp = 0,01; zmienne: *Count*, *relevant_experience*, *enrolled_university*, *education_level*, *experience*, *training_hours*; *city_development_index*;
- tree_2.3: minbucket = 500, maxdepth = 5, cp = 0,01; zmienne: *Count*, *relevant_experience*, *enrolled_university*, *education_level*, *experience*, *training_hours*; *city_development_index*;

Na koniec wykonaliśmy drzewo i las do finalnej analizy na innej próbie:

- tree_2.3 oraz rf_2.3: minbucket = 500, maxdepth = 5, cp = 0,01; zmienne: *Count*, *relevant_experience*, *enrolled_university*, *education_level*, *experience*, *training_hours*; *city_development_index*;

3.3 Zmienne potencjalne i w modelu


Do próby stworzenia odpowiedniego modelu użyliśmy przy drzewie *tree_1.1* wszystkich zmiennych objaśniających, które uznaliśmy za zasadne oprócz *city_development_index*, a do pozostałych drzew już z tą zmienną.

W wybranym modelu wygenerowanym przez program RStudio z największą istotnością znalazły się zmienne: *city_development_index*, *Count*, *experience*, *training_hours*. Oznacza to, że z 7 potencjalnych zmiennych objaśniających w różnych modelach zostało użytych 4 zmiennych. Pozostałe zmienne również znalazły się w innych modelach, jednak nie tych najlepszych..

3.4 Wynik i kolejne etapy budowania modelu


W pierwszej kolejności zostały utworzone testowe drzewa losowe na podstawie utworzonej próby treningowej z podstawowej bazy obserwacji pomniejszonej o niepotrzebne zmienne objaśniające.

Tree_1.1



Źródło: opracowanie własne w programie RStudio

Tree_1.2



Źródło: opracowanie własne w programie RStudio

W przypadku *tree_1.3* uznaliśmy, że wykorzystywanie tak pogłębionego drzewa nie będzie miało istotnego wpływu na analizę końcową. Wykonaliśmy jednak i dla niego ewaluację modelu, jak i dla 2 pozostałych modeli. Poniżej znajdują się kolejne screeny z ewaluacjami: rysunek 2.1 dla *tree_1.1*, rysunek 2.2 dla *tree_1.2* oraz rysunek 2.3 dla *tree_1.3*.

Rys. 2.1

Confusion Matrix and Statistics

	0	1
0	3330	849
1	262	379

Accuracy : 0.7695
 95% CI : (0.7573, 0.7813)
 No Information Rate : 0.7452
 P-Value [Acc > NIR] : 5.002e-05

Kappa : 0.2797

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9271
 Specificity : 0.3086
 Pos Pred Value : 0.7968
 Neg Pred Value : 0.5913
 Prevalence : 0.7452
 Detection Rate : 0.6909
 Detection Prevalence : 0.8670
 Balanced Accuracy : 0.6178

Rys.2.2

Confusion Matrix and Statistics

	0	1
0	3289	757
1	303	471

Accuracy : 0.7801
 95% CI : (0.7681, 0.7917)
 No Information Rate : 0.7452
 P-Value [Acc > NIR] : 9.359e-09

Kappa : 0.3406

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9156
 Specificity : 0.3836
 Pos Pred Value : 0.8129
 Neg Pred Value : 0.6085
 Prevalence : 0.7452
 Detection Rate : 0.6824
 Detection Prevalence : 0.8394
 Balanced Accuracy : 0.6496

Źródło: opracowanie własne w RStudio

Rys.2.3

Confusion Matrix and Statistics

	0	1
0	3285	798
1	307	430

Accuracy : 0.7707
 95% CI : (0.7586, 0.7826)
 No Information Rate : 0.7452
 P-Value [Acc > NIR] : 2.125e-05


Kappa : 0.3048

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9145
 Specificity : 0.3502
 Pos Pred Value : 0.8046
 Neg Pred Value : 0.5834
 Prevalence : 0.7452
 Detection Rate : 0.6815
 Detection Prevalence : 0.8471
 Balanced Accuracy : 0.6323


Przy tworzeniu kolejnych drzew zdecydowaliśmy się zastosować oversampling obserwacji w celu zmniejszenia dysproporcji klas, ponieważ początkowo klasa “0” stanowiła aż 80% wszystkich obserwacji. Doprowadzało to do tego, że poprzednie drzewa nie będą odpowiednie do interpretacji wyników. Użyliśmy do tego metody SMOTE.

Tree_2.1




Źródło: opracowanie własne w programie RStudio

Tree_2.2



Źródło: opracowanie własne w programie RStudio

Tree_2.3



Źródło: opracowanie własne w programie RStudio

Również dla tych drzew wykonaliśmy ewaluacje: rysunek 2.4 dla *tree_2.1*, rysunek 2.5 dla *tree_2.2* oraz rysunek 2.6 dla *tree_2.3*.

Rys. 2.4

Confusion Matrix and Statistics

	0	1
0	7135	2300
1	329	1432

Accuracy : 0.7652
95% CI : (0.7572, 0.773)
No Information Rate : 0.6667
P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.3913

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9559
Specificity : 0.3837
Pos Pred Value : 0.7562
Neg Pred Value : 0.8132
Prevalence : 0.6667
Detection Rate : 0.6373
Detection Prevalence : 0.8427
Balanced Accuracy : 0.6698

Rys. 2.5

Confusion Matrix and Statistics

	0	1
0	7417	2268
1	47	1464

Accuracy : 0.7932
95% CI : (0.7856, 0.8007)
No Information Rate : 0.6667
P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.4535

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9937
Specificity : 0.3923
Pos Pred Value : 0.7658
Neg Pred Value : 0.9689
Prevalence : 0.6667
Detection Rate : 0.6625
Detection Prevalence : 0.8650
Balanced Accuracy : 0.6930

Źródło: opracowanie własne w programie RStudio

Rys. 2.6

Confusion Matrix and Statistics

	0	1
0	6899	1847
1	565	1885

Accuracy : 0.7846
95% CI : (0.7768, 0.7922)
No Information Rate : 0.6667
P-Value [Acc > NIR] : < 2.2e-16


Kappa : 0.4697

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9243
Specificity : 0.5051
Pos Pred Value : 0.7888
Neg Pred Value : 0.7694
Prevalence : 0.6667
Detection Rate : 0.6162
Detection Prevalence : 0.7812
Balanced Accuracy : 0.7147

Sklaniając się ku prawidłowości *tree_2.3* stworzyliśmy je powtórnie na podstawie innej próby. Poniżej zamieszczone zostały ewaluacja oraz utworzone drzewo.

Tree_2.3_Final



Źródło: opracowanie własne w programie RStudio

Rys. 2.7

Confusion Matrix and Statistics

	0	1
0	6712	2089
1	284	1409

Accuracy : 0.7739
 95% CI : (0.7657, 0.7818)
 No Information Rate : 0.6667
 P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.4159

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9594
 Specificity : 0.4028
 Pos Pred Value : 0.7626
 Neg Pred Value : 0.8323
 Precision : 0.7626
 Recall : 0.9594
 F1 : 0.8498
 Prevalence : 0.6667
 Detection Rate : 0.6396
 Detection Prevalence : 0.8387
 Balanced Accuracy : 0.6811

Źródło: opracowanie własne w programie RStudio

Na podstawie ponownie wykonanego *tree_2.3*, po usunięciu wartości “NA” z oversamplowanego zbioru wykonaliśmy las *rf_2.3*. (rysunek 2.8 oraz wykres 1.9).

Rys. 2.8

Confusion Matrix and Statistics

	0	1
0	6357	1296
1	323	2109

Accuracy : 0.8395
95% CI : (0.8322, 0.8466)
No Information Rate : 0.6624
P-Value [Acc > NIR] : < 2.2e-16


Kappa : 0.614

McNemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9516
Specificity : 0.6194
Pos Pred Value : 0.8307
Neg Pred Value : 0.8672
Precision : 0.8307
Recall : 0.9516
F1 : 0.8870
Prevalence : 0.6624
Detection Rate : 0.6303
Detection Prevalence : 0.7588
Balanced Accuracy : 0.7855

Źródło: opracowanie własne w programie RStudio

Wyk. 1.9



Źródło: opracowanie własne w programie RStudio

4. Ocena jakości

4.1 Zbiór wykorzystany do oceny jakości

Do oceny skuteczności modeli użyto zbioru testowego, który stanowił 25% wszystkich obserwacji zarówno dla ilości przed, jak i po oversamplingu. Początkowo zbiór ten wynosił 4766 obserwacji, a po oversamplingu 10845. Przy tworzeniu *lasu_rf* zbiór został zmniejszony do 10282 obserwacji.

4.2 Wskaźniki oceny jakości modeli

4.2.1 Porównanie *tree_1.2* oraz *tree_2.3_final*

Początkowo porównaliśmy ze sobą wskaźniki ROC, AUC, LIFT oraz porównanie *trade off* dla *tree_1.2* oraz *tree_2.3_final*, które wydawały się dla nas najlepsze wśród 2 pozostałych drzew ze swoich grup.

Rys. 3.1

[1] 0.6688669

Źródło: opracowanie własne w programie RStudio

Rys. 3.2

[1] 0.8122529


Źródło: opracowanie własne w programie RStudio

Rysunek 3.1 pokazuje wartość AUC dla *tree_1.2*, a rysunek 3.2 dla *tree_2.3_final*. Widać dość znaczącą różnicę między tymi dwoma modelami.

Również wykres 2.1 wskazuje różnicę między dwoma modelami drzew dla wskaźnika ROC. Linia bardziej zaokrąglona odpowiada *tree_2.3_final*, a linia poniżej niej odpowiada *tree_1.2*.


Na podstawie ROC i AUC lepszym modelem w tym przypadku okazał się *tree_2.3_final*. Oznacza to, że ten model ma większą zdolność do rozróżniania między dwoma klasami.

Wyk. 2.1



Źródło: opracowanie własne w programie RStudio


Wyk. 2.2



Źródło: opracowanie własne w programie RStudio

Na wykresie 2.2 czerwoną linią zaznaczony jest wskaźnik LIFT dla *tree_1.2*, a niebieską *tree_2.3_final*. Wskaźnik LIFT to miara używana w analizie klasyfikacyjnej, zwłaszcza w kontekście modeli predykcyjnych, aby ocenić efektywność modelu w identyfikowaniu interesujących przypadków. Wskaźnik ten pomaga zrozumieć, jak bardzo model przewyższa losowe zgadywanie w identyfikacji pozytywnych przypadków. W przypadku porównywania obu modeli można zauważyć, że niebieska linia ma wysoką wartość początkową, a potem szybko spada, co charakteryzuje dobry model.

Wyk. 2.3



Źródło: opracowanie własne w programie RStudio

Ciemniejsza linia charakteryzuje model *tree_2.3_final*. Płynnie przechodzi ona między wartościami *sensitivity*, a *specificity*. Oznacza to, że w porównaniu do modelu zaznaczonego szarą linią, odpowiadającego modelowi *tree_1.2*, cechuje się on mniejszą czułością na zmiany pomiędzy tymi dwoma metrykami.

4.2.2 Porównanie *tree_2.3_final* oraz lasu *rf_2.3*

Kolejnym punktem było porównanie modelu *tree_2.3_final* do lasu *rf_2.3*. Pod uwagę wzięliśmy te same wskaźniki co w przypadku wcześniejszego porównywania.


Rys. 3.3

[1] 0.8763104

Źródło: opracowanie własne w programie RStudio

Wskaźnik AUC dla *rf_2.3* na rysunku 3.3 wyszedł większy niż był dla drzewa *tree_2.3_final* (0,81).

Wyk. 2.4




Źródło: opracowanie własne w programie RStudio

Również na wykresie 2.4 wskaźnik ROC wskazuje, że las (krzywa położona wyżej, bardziej wygładzona) odznacza się lepszą zdolnością do rozróżniania pomiędzy dwoma klasami od drzewa *tree_2.3_final*.

Na wykresie 2.5 czerwoną linią zaznaczony jest wskaźnik LIFT dla *tree_2.3_final*, a niebieską dla lasu *rf_2.3*. Jak pisaliśmy wcześniej LIFT pomaga ocenić efektywność modelu w identyfikowaniu


interesujących przypadków. Porównując oba modele, wskaźnik ten jest lepszy dla lasu. Również rozpoczyna się od dużej wartości, a potem szybko opada, jednak powyżej czerwonej linii.

Wyk. 2.5



Źródło: opracowanie własne w programie RStudio

Wyk. 2.6



Źródło: opracowanie własne w programie RStudio

Ostatnim wskaźnikiem, który sprawdziliśmy dla tego przypadku był *trade_off* pomiędzy *sensitivity*, a *specificity*. Na wykresie 2.6 czarna linia oznacza model *rf_2.3*, a czerwona *tree_2.3_final*. Łatwo można zauważyć, że dla lasu linia jest położona znacznie wyżej niż dla drzewa. Oznacza to, że las odznacza się mniejszą czułością przy zmianie pomiędzy tymi dwoma wartościami.

4.3 Wybór modelu

Na podstawie przeprowadzonych porównań i wygenerowanych modeli, doszliśmy do wniosku, że najlepszym modelem jest las *rf_2.3*. Drzewo *tree_1.2*, przez wzgląd na dość dużą dysproporcję pomiędzy klasami pozytywną i negatywną posiadało słabe wartości wskaźników już w porównaniu do drzewa z oversamplingowanymi wartościami - *tree_2.3_final*. Tu natomiast lepszymi wartościami (co pokazały również wykresy wskaźników) i najlepszym modelem okazał się las *rf_2.3*. Również powracając do jego ewaluacji można było zauważyć dużo lepsze wartości pozostałych metryk.

5. Wyniki i interpretacja

5.1 Wyniki “techniczne”

W wyniku stworzenia różnych modeli drzew i lasu, najlepszy przy naszych obserwacjach okazał się być las *rf_2.3*. Dla wszystkich wskaźników AUC, LIFT, ROC oraz *trade_off* odznaczał się zarówno na wykresach jak i wartościowo w porównaniu do pozostałych. Dodatkowo na podstawie macierzy błędów można zauważyć, że wszelkie metryki tam zawarte w porównaniu do innych modeli mają lepsze wartości.

Jeżeli chodzi o jakość dostępnych zmiennych i ich dopasowanie do zmiennej objaśnianej, to mamy małą wartość R-kwadrat oraz skorygowanego R-kwadrat. Dodatkowo również korelacje zmiennych objaśniających są słabe lub bardzo słabe, co utrudnia wnioskowanie i predykcję przyszłych zmiennych.

Poprawa modeli po zastosowaniu oversamplingu potwierdza, że różnica w ilości obserwacji należących do klasy pozytywnej lub negatywnej była zbyt duża w przypadku podstawowej zawartości.

Powyższe wnioski świadczą o tym, że model nie jest idealny i posiada słabe strony w szczególności w przypadku jakości początkowych obserwacji. Możliwe, że dodanie dodatkowych zmiennych z

innych źródeł polepszyłoby model, a także skuteczność zmiennych do wyjaśniania zmiennej objaśnianej.

5.2 Interpretacja

Biorąc pod uwagę model lasu, najlepiej problem wyjaśniają zmienne *city_development_index* oraz *count*. Pośrednio również *experience* oraz *training_hours*.

Firma z obszaru Data Science i Big Data, przy przyjmowania na swoje szkolenia powinna brać pod uwagę wyżej wymienione czynniki. Nie oznacza to jednak, że wyznaczą one w 100% kierunek, na podstawie którego osoby decyzyjne będą podejmować działania w celu oszczędności i ograniczenia czasu. Jak wykazały sporządzone modele, bazowanie jedynie na zawartych zmiennych nie pozwala na odpowiednie przewidzenie przyszłych decyzji kursantów.

Reasumując, firma przy naborze może skupić się na danych zmiennych, jednak powinna również sprawdzić inne czynniki zewnętrzne lub wewnętrzne, które mają wpływ na podjęcie decyzji o opuszczeniu firmy po ukończonych w niej szkoleniach.

6. Bibliografia

- dane: <https://www.kaggle.com/datasets/arashnic/hr-analytics-job-change-of-data-scientists>
- wartości i wykresy: sporządzone na podstawie kodu własnego w programie RStudio